

自然語言處理 期末專題

-----檢索系統

組員:王睿毅4111056003

、邱睿棋4111056025、孟令桓4111056030



簡報段落

1.核心架構

2.資料庫建置

3.資訊檢索

4.輸出答案

5.最終結果

1. 核心架構



核心架構

在本專案中我們使用資料檢索+語言模型生成回答的方式完成問答系統



2. 資料庫建置



資料庫建置

由於講義是PDF的形式，較不利於資料檢索的進行，因此將講義(包含課程資訊)從ilearning下載後做以下處理

1. 利用pypdf套件提取PDF內容
2. 用chatGPT處理圖片
3. 轉換成json格式方便後續利用



pypdf
BACK TO THE ROOTS


提取PDF文字

pypdf套件可以將所有講義轉換成純文字，然而對於圖片部分可說是束手無策，並且沒有將頁數與內容以程式看得懂的方式對應起來

Named Entity Recognition

- Named entity recognition (NER) 讓我們能夠識別(即標記)文件中的所有人名、地名和公司名稱。
- 和 parts-of-speech tagging 一樣類型的任務 (many-to-many)

Entities



講義內容

pypdf

===== Page 3 =====

Named Entity Recognition

- Named entity recognition (NER) 讓我們能夠識別(即標記)文件中的所有人名、地名和公司名稱。
- 和 parts-of-speech tagging 一樣類型的任務 (many-to-many)

示意圖資訊消失

頁數也以純文字輸出


用ChatGPT處理圖片

對於圖片的轉換則是把講義人工送進ChatGPT
使其將講義瀏覽後把有圖片的頁面生成一段描述
圖片的文字

Named Entity Recognition

- Named entity recognition (NER) 讓我們能夠識別(即標記)文件中的所有人名、地名和公司名稱。
- 和 parts-of-speech tagging 一樣類型的任務 (many-to-many)

Entities



講義內容

ChatGPT

Page 3 - Named Entity Recognition (NER)

範例句：

Steve Jobs was the CEO of Apple, headquartered in California.

圖中以不同顏色框選實體：

- Steve Jobs → PER (Person)
- Apple → ORG (Organization)
- California → LOC (Location)

展示 NER 如何將非結構化文字轉換為結構化實體資訊。

圖片的文字敘述

轉換成json檔

將PDF文字與圖片文字敘述串接在一起轉換成JSON的結構，標記來源、頁數、內容，並且將多份講義的內容合併成一個檔案，供後續檢索使用

```
{"source": "c9_advanced_nlp_tasks.pdf", "page": 1, "text": "Announcement\n● 期末考\nno 6/3 (三)14:10 ~ 16:00\nno 地點：337, 338 (請參考ilearning 公告)\nno 範圍C6~C9\nno No open boo"}
{"source": "c9_advanced_nlp_tasks.pdf", "page": 2, "text": "Advanced NLP Tasks", "original_text": "Advanced NLP Tasks"}
{"source": "c9_advanced_nlp_tasks.pdf", "page": 3, "text": "Named Entity Recognition\n● Named entity recognition (NER) 讓我們能夠識別（即標記）文件中的所有人名、\n地名和公司名稱。"}
{"source": "c9_advanced_nlp_tasks.pdf", "page": 4, "text": "NER 的挑戰\n● 有些實體會跨越多個詞元（例如 “Steve” 和 “jobs”）\n● 同一個詞在不同語境下可能代表不同實體類別（ex: “Apple”"}
{"source": "c9_advanced_nlp_tasks.pdf", "page": 5, "text": "NER 的挑戰\n● 有些實體會跨越多個詞元（例如 “Steve” 和 “jobs”）\n● 同一個詞在不同語境下可能代表不同實體類別（ex: “Apple”"}
{"source": "c9_advanced_nlp_tasks.pdf", "page": 6, "text": "NER 模型演進\n1. 傳統模型：CRF、HMM，依賴人工特徵（POS、位置等）\n2. 深度學習模型：BiLSTM + CRF（引入上下文，但需大量訓練
```

JSON格式

3. 資訊檢索



資訊檢索

資訊檢索階段的核心為TF-IDF，本階段會將Query的字句對JSON檔內的資料作比對，找出最高分的幾個內容送入後續語言模型做答案生成



資訊檢索

然而直接做TF-IDF會有以下問題

1. 提問關鍵字不精準
2. 語言不符
3. 同義字影響TF-IDF
4. 某些內容橫跨多頁或在不同的地方(多跳)



提問關鍵字不精準

如果使用者的提問與用詞不夠精準或過於簡略
可能會沒辦法正確定位到關鍵頁面

因此在query進來後會先用GPT的API進行重寫，將句子改的更完整，以及針對一些專有名詞寫成常見的完整名稱

ex:

問題:NTP的各式採樣差別



講義該頁並非NTP簡寫
講義未提到"差別"字眼
沒有完整寫出"採樣策略"

Rewrite:比較Next Token Prediction各式採樣策略的優點與缺點

語言不符

講義內容為中英混雜，若提問時的語言與講義內實際語言不符，可能無法準確搜尋到正確內容

ex:

講義:The Markov Property

提問:馬可夫性質是什麼



講義內容為英文
提問為中文

講義:期末考時間.....

提問:什麼時候final exam



講義內容為中文
提問中英混雜且關鍵部分
語言不符

語言不符

將query先用GPT的API翻譯重寫成全英文(配合前段的query重寫)接著再把英文翻成全中文，以確保英文中文都有，並且保留原始query一起串接在後面避免發生原始問句反而更接近講義內容卻被丟棄的狀況

原始問句

翻譯成英文

純英文句子

翻譯成中文

純中文句子

串接三部分

輸出問句:

原始問句

純英文句子

純中文句子

同義字影響TF-IDF

假設使用者輸入同義字，則TF-IDF將會失去用處
例如：

Query: 教授休息室在哪裡？

講義內容: 老師的辦公室在理學812

Expand: 教授的休息室在哪裡？老師、teacher、辦公室


串接可能的關鍵詞同義字

因此我們在查詢前會先將Query交給GPT進行擴增(expand)
關鍵字，增加命中實際用詞的機會，以利於TF-IDF能生效。

內容橫跨多頁

我們的TF-IDF向量建立方法是以三頁為一個段落進行切分(重疊)，如此可以避免只抓到答案的部分內容的問題。

查詢是與段落進行相似度比對。



內容在不同段落

為了處理多跳問題，因此我們會將段落排名並取前三名作為目標段落。

聰明的你一定想到，相鄰段落的分數會很相近，那麼即使取前三名也還是會拿到相鄰段落。


所以當選到目標段落時，會自動將其相鄰段落捨棄，以避免重複停留在同一個區域。

4.輸出答案




生成式回答

資料檢索成功得到相關內容後，會與原始query一併送進ChatGPT做統整輸出，讓GPT根據檢索到的內容以符合人類語言的句子回答原始query，而不是直接輸出內容片段的抽取式回答



例外處理


若真的因種種原因沒有檢索到合適內容，則直接交由Chat GPT依自己的知識嘗試回答提問，避免發生沒有回答的狀況



4.最終結果



完整問答流程



實機畫面

Query

```
python rag_answer.py "where is the teacher officer" --llm openai
```

Answer

```
Answer:  
老師的辦公室在理學大樓 (science building) 812 室，建議事先透過電子郵件 (albert.yang@nchu.edu.tw) 預約。(參見 c0_course_introduction.pdf 頁3)
```

Source

```
Sources:  
- c6_transformer.pptx.pdf page 42  
- c6_transformer.pptx.pdf page 43  
- c6_transformer.pptx.pdf page 44  
- c6_transformer.pptx.pdf page 11  
- c6_transformer.pptx.pdf page 12  
- c6_transformer.pptx.pdf page 13  
- c7_QA_system.pdf page 16  
- c7_QA_system.pdf page 17  
- c7_QA_system.pdf page 18
```


實機畫面(詳細版)

參數: --show-query --show-context

rewrite

```
PS C:\Users\user\Desktop\nchu資料\課程資料\自然語言處理\期末專題> python rag_answer.py "where is the teacher officer" --llm openai --show-query --show-context
Rewritten query: location of faculty offices in universities | 大學教職員辦公室的位置
Retrieval query: where is the teacher officer | location of faculty offices in universities | 大學教職員辦公室的位置
Expanded query: where is the teacher officer | location of faculty offices in universities | 大學教職員辦公室的位置 office room
```

TFIDF
抓取頁面

```
Retrieved context:
[c0_course_introduction.pdf page 2, score=0.2167]
Natural Language Processing

[c0_course_introduction.pdf page 3, score=0.2167]
Teacher, I have questions Lecturer: - Office: science building (理學大樓) 812 room - Email: albert.yang@nchu.edu.tw TA: - 實驗室: science building (理學大樓) 902 room - Email: rogerwu212@gmail.com Making an appointment through email in advance is highly recommended!!

[c0_course_introduction.pdf page 4, score=0.2167]
Grading policy • 期中考 (20%) • 期末考 (20%) • 課堂練習 (20%) • 期末專題 (30%) • 出席 (10%)

[c9_advanced_nlp_tasks.pdf page 1, score=0.1100]
Announcement • 期末考 o 6/3 (三)14:10 ~ 16:00 o 地點: 337, 338 (請參考ilearning 公告) o 範圍C6~C9 o No open book o 考試開始30分鐘後不得入場 • 第十六週為期末專題週 o 可至上課教室確認期末考成績和詢問期末專題相關事項

[c9_advanced_nlp_tasks.pdf page 2, score=0.1100]
```

實機畫面(CSV多筆問題)

參數: --input.csv

```
PS C:\Users\user\Desktop\nchu資料\課程資料\自然語言處理\期末專題> python rag_answer.py input.csv --llm openai --input_csv
[1/4] 什麼是自然語言處理 (NLP)?
[2/4] 請列出三種 NLP 的常見應用。
[3/4] 什麼是 N-Gram 模型?
[4/4] 在機率模型中，什麼是馬可夫性質 (Markov Property)?
Saved answers to: input_answers.csv
```



謝謝觀看